

„ Analiza imaginilor cu fund de ochi pentru ajutor în diagnosticul retinopatiei diabetice”

Student Stancovici Marian
Profesor Coordonator
Conf. Dr. Ing. Laura-Maria Florea

1. Introducere / Motivare

- Retinopatia diabetică este o cauză majoră de pierdere prevenibilă a vederii.
- Screening-ul automat poate sprijini medicii prin trierea rapidă a imaginilor fundus.
- Problema este dificilă deoarece clasele 0–4 sunt ordonate clinic, iar leziunile incipiente sunt subtile.

2. Stadiul actual al domeniului





- Metodele moderne folosesc rețele CNN și transfer learning pentru clasificarea imaginilor retiniene.
- Literatura evidențiază arhitecturi precum ResNet, Inception, EfficientNet și modele explicabile.
- Provocări: dezechilibru de clase, variații între dataset-uri și risc de data leakage.

5. Rezultate

- Model binar EfficientNet-B3: cel mai bun AUC pe validare = 0,8602.
- Cross-entropy multiclasă: Accuracy test = 0,6618; QWK = 0,6247.
- Regresie 1–4: QWK test = 0,6440, cu praguri optimizate pe validare.
- Formularea ordinală obține cel mai bun QWK test = 0,6561; 93,2% dintre erori sunt la un singur grad.

3. Contribuția studentului

- Construirea unui pipeline PyTorch pentru încărcare, preprocesare, antrenare și evaluare.
- Compararea arhitecturilor și funcțiilor de pierdere pe seturi APTOS, EyePACS și Balanced_Aug.
- Identificarea data leakage în Diabetic_Balanced_Data și folosirea unui split grupat.
- Integrarea modelelor într-o aplicație web de inferență Flask + React.
- Integrarea cu sistemul final în două etape: binarizare -> clasificare



6. Concluzii

- Sistemul demonstrează utilitatea transfer learning pentru analiza imaginilor fundus.
- Abordarea în două etape permite separarea detecției bolii de gradarea severității.
- Direcții viitoare: augmentări mai robuste, Visual Transformers și cascadă binar + regresie 0–4

4. Evaluarea performanțelor

- Metrice urmărite: Accuracy, Macro F1, AUC și Quadratic Weighted Kappa.
- Analiza include matrice de confuzie, curbe ROC și rapoarte precision/recall/F1.
- Experimentele finale separă detecția binară de gradarea severității pe clasele 1–4.
- Validarea urmărește atât scorul global, cât și distanța clinică dintre clasele confundate.

