

Proiect Integrator de Cercetare

Analiza imaginilor cu fund de ochi pentru ajutor în
diagnosticul retinopatiei diabetice

Master: TAID

Profesor coordonator: Laura Maria Florea

Student: Stancovici Marian

Capitolul 1

Introducere

Retinopatia diabetică reprezintă o provocare majoră de sănătate publică, fiind principala cauză a orbirii prevenibile în rândul populației active. Creșterea continuă a numărului de pacienți cu diabet generează o presiune imensă asupra sistemelor medicale, depășind adesea capacitatea de screening a specialiștilor. Deoarece afecțiunea poate evolua asimptomatic în fazele inițiale, identificarea pacienților la risc este critică înainte ca leziunile retiniene să devină ireversibile, subliniind necesitatea unor soluții de monitorizare scalabile și eficiente.

Complexitatea diagnosticării este dată de necesitatea unei stadializări precise, conform standardelor internaționale care împart boala în cinci clase de severitate. Procesul impune medicului să distingă între stadiile incipiente, marcate doar de microanevrisme discrete, și formele avansate, caracterizate de hemoragii și neovascularizație. Această granularitate a diagnosticului este dificil de menținut constant în programele de screening de masă, unde oboseala și subiectivitatea factorului uman pot duce la erori de clasificare cu impact direct asupra deciziilor terapeutice.

Pentru a depăși aceste limitări, domeniul imagisticii medicale a adoptat rapid soluțiile bazate pe inteligență artificială. Trecerea de la metodele clasice de procesare a imaginii la algoritmii de învățare profundă (Deep Learning) a marcat un punct de inflexiune. Rețelele neurale convoluționale au eliminat necesitatea definirii manuale a regulilor vizuale, având capacitatea de a învăța autonom trăsături complexe direct din datele brute și de a identifica corelații subtile între texturi și patologie.

Evoluția recentă a acestor tehnologii a permis tranziția de la modele experimentale simple la arhitecturi robuste, capabile să opereze în condiții clinice reale. Cercetarea actuală s-a distanțat de clasificarea binară elementară, concentrându-se pe sisteme sofisticate care pot gestiona variabilitatea imaginilor provenite din diverse surse. Algoritmii moderni demonstrează o reziliență crescută la artefacte și zgomot vizual, oferind o consistență a diagnosticului care rivalizează cu expertiza umană.

Astfel, inteligența artificială devine un instrument indispensabil de triaj asistat, cu potențialul de a transforma radical accesul la îngrijirea oftalmologică. Prin procesarea rapidă și obiectivă a volumelor mari de date, aceste sisteme promit să eficientizeze fluxurile medicale și să asigure o detecție timpurie a bolii, redefinind standardele de prevenție a orbirii la nivel global.

Capitolul 2

SOTA: State of the Art

Primele metode computaționale pentru detecția retinopatiei diabetice s-au bazat pe tehnici clasice de procesare a imaginilor și învățare automată, incluzând segmentarea structurilor relevante, extracția manuală de trăsături și clasificatoare precum SVM, k-NN sau Random Forest [1], [2]. Deși promițătoare, aceste abordări erau limitate de capacitatea redusă de generalizare și de dependența puternică de ingineria manuală a caracteristicilor.

O schimbare fundamentală a apărut odată cu dezvoltarea rețelelor neuronale convoluționale (CNN), care permit învățarea automată a reprezentărilor direct din date brute. Începând cu 2015, modelele CNN precum VGG, ResNet și Inception au devenit dominante în analiza imaginilor fundus, atingând performanțe comparabile cu cele ale experților umani, fapt demonstrat de lucrări de referință precum cele ale lui Gulshan et al. și Pratt et al. [3], [4].

Ulterior, cercetarea s-a extins către sarcini mai complexe, precum clasificarea pe stadii de severitate, segmentarea semantică a leziunilor și localizarea zonelor patologice. Arhitecturi dedicate, precum U-Net și derivatele sale, au permis o detecție precisă a leziunilor, iar modelele multi-task au demonstrat o mai bună robustețe și generalizare [5], [6].

Direcțiile recente includ integrarea mecanismelor de atenție și a transformatoarelor vizuale, care modelează relațiile globale din imagine și îmbunătățesc detecția leziunilor subtile [7], precum și dezvoltarea metodelor de inteligență artificială explicabilă. În paralel, tehnicile de *domain adaptation* și transfer learning sunt investigate intens pentru a asigura generalizarea pe date eterogene și performanță stabilă în contexte clinice reale [8].

Inception-v3 – Deep Learning pentru detectarea clinică a retinopatiei diabetice [3]

Studiul realizat de Gulshan et al. și publicat în *Journal of the American Medical Association* (JAMA) în 2016 este considerat un reper major în literatura de specialitate, marcând una dintre primele validări clinice riguroase ale utilizării rețelelor neuronale convoluționale pentru screening-ul automat al retinopatiei diabetice. Lucrarea demonstrează că un sistem de deep learning poate atinge și chiar depăși performanța medie a medicilor oftalmologi în detectarea retinopatiei diabetice referabile, contribuind decisiv la acceptarea inteligenței artificiale în aplicații medicale reale [3].

Arhitectura utilizată este Inception-v3, o rețea convoluțională profundă caracterizată prin utilizarea modulelor Inception, care combină în paralel convoluții de dimensiuni diferite (1×1, 3×3, 5×5) și operații de pooling. Această strategie permite captarea informațiilor la multiple scări spațiale și reduce costul computațional prin utilizarea convoluțiilor 1×1 pentru diminuarea dimensionalității. Datorită

acestei structuri, modelul este capabil să învețe reprezentări vizuale complexe, esențiale pentru identificarea leziunilor subtile specifice retinopatiei diabetice.

Modelul a fost antrenat pe un set de date extins, alcătuit din peste 128.000 de imagini fundus color, etichetate independent de mai mulți medici oftalmologi certificați. Utilizarea consensului între experți a contribuit la reducerea subiectivității etichetelor și la creșterea fiabilității procesului de antrenare. Sarcina principală a rețelei a fost clasificarea imaginilor în funcție de prezența sau absența retinopatiei diabetice referabile, conform standardelor clinice acceptate internațional [3].

Preprocesarea imaginilor a inclus decuparea automată a regiunii retiniene, redimensionarea la o rezoluție compatibilă cu Inception-v3 și normalizarea intensității pixelilor. În plus, au fost aplicate tehnici extensive de augmentare a datelor, precum rotații, translații și ajustări de luminozitate și contrast, pentru a îmbunătăți generalizarea și a reduce supraînvățarea [3], [10].

Evaluarea performanței a fost realizată pe seturile de date EyePACS-1 și Messidor-2, unde modelul a obținut o arie sub curba ROC (AUC) de aproximativ 0.99 pentru detectarea retinopatiei diabetice referabile, cu valori ridicate de sensibilitate și specificitate, comparabile cu performanța medicilor oftalmologi experimentați [3], [4].

Transfer Learning pentru diagnosticul retinopatiei diabetice [10]

Lucrarea propusă de Jabbar et al. abordează problema diagnosticului automat al retinopatiei diabetice dintr-o perspectivă practică, concentrându-se pe utilizarea tehnicilor de transfer learning pentru a compensa limitările impuse de dimensiunea redusă a seturilor de date medicale etichetate. Studiul evidențiază faptul că modelele CNN pre-antrenate pe seturi de date generale de mari dimensiuni, precum ImageNet, pot fi adaptate eficient pentru analiza imaginilor fundus, obținând performanțe competitive cu un cost de antrenare semnificativ redus [10].

Autorii investighează mai multe arhitecturi consacrate de rețele neuronale convoluționale, printre care VGG16, VGG19, ResNet50, Inception-v3 și DenseNet, utilizate ca extractoare de caracteristici. Strategia de transfer learning constă în inițializarea rețelelor cu greutatea pre-antrenate, urmată de ajustarea straturilor superioare pentru sarcina specifică de clasificare a retinopatiei diabetice. În unele experimente, straturile convoluționale inferioare sunt înghețate pentru a preveni supraînvățarea, în timp ce în altele este aplicat fine-tuning progresiv pentru a îmbunătăți adaptarea la domeniul imagisticii medicale. Una din abordările propuse poate fi observată în figura 1.




Figura 1. Framework propus pentru detectarea și clasificarea retinopatiei diabetice [10]

Seturile de date utilizate includ imagini fundus publice, preprocesate prin redimensionare, normalizare și augmentare extensivă a datelor. Tehnicile de augmentare, precum rotațiile, flip-urile orizontale și ajustările de luminozitate, joacă un rol central în creșterea diversității artificiale a datelor și în îmbunătățirea capacității de generalizare a modelelor. Această etapă este esențială în contextul transfer learning-ului, unde diferențele de distribuție dintre datele naturale și imaginile medicale pot afecta performanța rețelelor [10].

Evaluarea performanței este realizată folosind metrice standard, precum acuratețea, sensibilitatea, specificitatea și scorul F1, permițând o comparație riguroasă între diferitele arhitecturi analizate. Rezultatele experimentale indică faptul că modelele bazate pe DenseNet și ResNet obțin performanțe superioare față de arhitecturile mai vechi, confirmând avantajele reutilizării caracteristicilor vizuale generale în sarcini medicale specializate. Studiul subliniază că transfer learning-ul reprezintă o soluție viabilă și eficientă pentru implementarea rapidă a sistemelor automate de screening în contexte cu resurse limitate [10].

Multi-task Learning pentru gradarea retinopatiei diabetice [6]

Lucrarea propusă de Wang et al., publicată în cadrul AAAI Conference on Artificial Intelligence (2021), introduce o abordare de tip *deep multi-task learning* pentru gradarea automată a retinopatiei diabetice, având ca obiectiv principal exploatarea relației clinice dintre severitatea bolii și prezența leziunilor retiniene specifice. Spre deosebire de metodele clasice de clasificare single-task, autorii demonstrează că învățarea simultană a mai multor sarcini corelate clinic conduce la reprezentări vizuale mai discriminative și la performanțe superioare în sarcina principală de gradare [6].

Arhitectura propusă este alcătuită dintr-un backbone convoluțional comun, bazat pe o rețea CNN profundă (ResNet18), utilizat pentru extracția caracteristicilor globale din imaginile fundus. Peste acest extractor comun sunt construite mai multe ramuri specializate (*task-specific branches*), fiecare

corespunzătoare unei sarcini distincte. Sarcina principală constă în clasificarea severității retinopatiei diabetice în mai multe stadii, în timp ce sarcinile auxiliare vizează detectarea prezenței diferitelor tipuri de leziuni, precum microanevrismele, exudatele dure, exudatele moi și hemoragiile, considerate markeri clinici relevanți ai progresiei bolii [6].

Un element central al arhitecturii îl reprezintă mecanismul de partajare controlată a caracteristicilor între sarcini. În locul unei separări rigide între ramuri, modelul permite propagarea informației relevante între sarcina de gradare și cele de detecție a leziunilor, încurajând învățarea unor reprezentări comune sensibile la semnalele patologice fine. Funcția de pierdere globală este definită ca o combinație ponderată a pierderilor individuale asociate fiecărei sarcini:

$$L_{\text{isr}} = \lambda_{\text{img}} \cdot L_{\text{img_isr}} + \lambda_{\text{tv}} \cdot L_{\text{tv_isr}} + \lambda_{\text{sa}} \cdot L_{\text{seg-aware}} + \lambda_{\text{ca}} \cdot L_{\text{cls-aware}}$$

,unde λ_{img} , λ_{tv} , λ_{sa} și λ_{ca} sunt hiperparametri care controlează contribuția pierderilor intra-task, segmentation-aware și classification-aware. Această formulare permite echilibrarea influenței fiecărei sarcini și stabilizează procesul de optimizare [6].

Modelul este antrenat și evaluat pe seturi de date publice de imagini fundus etichetate atât cu stadiul retinopatiei diabetice, cât și cu adnotări la nivel de imagine privind prezența leziunilor. Imaginile sunt supuse unor etape standard de preprocesare, incluzând decuparea regiunii retiniene, redimensionarea și augmentarea datelor, pentru a reduce variațiile de iluminare și pentru a îmbunătăți capacitatea de generalizare. Prin includerea sarcinilor auxiliare, modelul beneficiază de un efect de regularizare implicită, reducând riscul de supraînvățare, aspect observat și în lucrările anterioare bazate pe CNN-uri single-task [3], [4].

Rezultatele experimentale raportate de Wang et al. indică îmbunătățiri consistente ale performanței față de modelele single-task, atât în termeni de acuratețe, cât și de scor F1 pentru sarcina de gradare a retinopatiei diabetice. În plus, autorii evidențiază o creștere a stabilității predicțiilor și o sensibilitate mai bună la stadiile intermediare ale bolii, considerate dificil de clasificat. Aceste rezultate confirmă faptul că integrarea informațiilor despre leziuni în procesul de antrenare contribuie direct la o evaluare mai precisă a severității retinopatiei diabetice și validează eficiența paradigmei multi-task learning în context clinic [6].

Analiza arhitecturii Modified U-Net [12] pentru segmentarea semantică

Segmentarea semantică a structurilor retiniene, în special a rețelei vasculare și a leziunilor asociate retinopatiei diabetice, reprezintă o etapă critică în diagnosticarea automată, deoarece modificările morfologice ale vaselor de sânge sunt adesea primii indicatori ai bolii. Deși arhitectura **U-Net**, introdusă inițial de **Ronneberger et al.** [5] pentru segmentarea biomedicală, a devenit standardul de aur în domeniu datorită structurii sale simetrice de tip encoder-decoder, aceasta prezintă limitări în detectarea vaselor capilare foarte fine, pierzând informații spațiale esențiale în procesul de sub-eșantionare.

În studiul "*Modified U-Net architecture for semantic segmentation of diabetic retinopathy images*", **Sambyal et al. [12]** propun o optimizare arhitecturală semnificativă pentru a contracara aceste deficiențe. Modelul propus, denumit **Modified U-Net**, păstrează structura în formă de „U” a rețelei originale, dar inovează fundamental la nivelul blocurilor de procesare.

Autorii au înlocuit blocurile convoluționale standard cu **blocuri reziduale (residual blocks)**, inspirate din arhitecturile de tip ResNet. Această modificare este crucială din punct de vedere tehnic: în rețelele adânci, apare frecvent problema dispariției gradientului (vanishing gradient), ceea ce face antrenarea dificilă și duce la pierderea detaliilor fine. Prin introducerea conexiunilor reziduale (skip connections la nivel de bloc), informația originală este propagată mai eficient prin straturi, permițând rețelei să învețe caracteristici complexe fără a degrada performanța pe detaliile de finețe, precum microanevrismele sau vasele subțiri. Aceste detalii se pot observa în figura 2, în arhitectura propusă în articol.




Figura 2. Arhitectura U-net modificată [12]

Importanța acestei abordări rezidă în capacitatea superioară de generalizare comparativ cu metodele clasice de procesare a imaginii, precum cele bazate pe clustering fuzzy propuse anterior de **Sopharak et al. [2]**. În timp ce metodele de tip clustering sunt sensibile la zgomot și la variațiile de iluminare (frecvente în imaginile de fund de ochi), arhitectura Modified U-Net demonstrează o robustețe sporită prin învățarea contextuală a trăsăturilor.

Pentru validarea performanței, metoda a fost testată pe seturile de date publice standardizate **DRIVE** și **STARE**, recunoscute pentru dificultatea lor în segmentarea vaselor.

Rezultatele experimentale raportate de Sambyal et al. [12] au indicat o îmbunătățire clară față de U-Net-ul standard. Pe setul de date DRIVE, autorii au obținut o acuratețe maximă de **96.94%** și o arie de sub curba ROC (AUC) de **0.98**, valori care plasează metoda în topul soluțiilor de segmentare. Mai mult, analiza vizuală a rezultatelor arată o continuitate mult mai bună a vaselor de sânge segmentate și o reducere a alarmelor false în zonele cu patologii, demonstrând că integrarea învățării reziduale în

arhitectura de segmentare este o direcție SOTA esențială pentru analiza detaliată a retinopatiei diabetice.

Tranziția către arhitecturi globale: RTNet (Relation Transformer Network) [7]

Dacă modelele bazate pe U-Net, precum cel discutat anterior [12], excelează în capturarea detaliilor locale, ele suferă totuși de o limitare inherentă a rețelelor convoluționale: incapacitatea de a modela dependențe la distanță mare (long-range dependencies). În patologia retiniană, leziunile nu apar izolat; există adesea o corelație spațială între poziția vaselor de sânge și apariția microanevrismelor sau a exudatelor. Pentru a adresa această lipsă de „context global”, **Huang et al. [7]** au propus în 2022 o schimbare de paradigmă prin introducerea **RTNet (Relation Transformer Network)**, o arhitectură care marchează trecerea către mecanismele de atenție.

Inovația centrală a RTNet constă în înlocuirea parțială a operațiilor convoluționale standard cu blocuri de tip Transformer, denumite **Relation Transformer Blocks (RTB)**. Spre deosebire de CNN-uri care „văd” doar o fereastră mică de pixeli la un moment dat, RTB-ul utilizează două mecanisme de atenție complementare:

1. **Self-Attention (Atenție proprie):** Permite modelului să înțeleagă relațiile dintre leziunile dispersate pe toată suprafața retinei (de exemplu, grupuri de exudate dure care semnalează o zonă de edem).
2. **Cross-Attention (Atenție încrucișată):** Aceasta este contribuția critică a lucrării. Autorii au observat că leziunile vasculare sunt strâns legate de structura vaselor de sânge. Astfel, mecanismul de cross-attention folosește harta vaselor de sânge ca un „ghid” pentru a localiza mai precis leziunile fine, transferând informație structurală dinspre ramura vasculară către ramura de detectare a leziunilor.

Pentru validare, metoda a fost testată pe seturile de date **IDRiD** și **DDR**, care conțin adnotări la nivel de pixel pentru multiple tipuri de leziuni. Rezultatele cantitative au demonstrat că RTNet depășește metodele SOTA anterioare (inclusiv diverse variante de U-Net și DeepLab), obținând cele mai bune scoruri de segmentare pentru **Exudate (EX)**, **Microanevrisme (MA)** și **Exudate Moi (SE)**.

Deși inovația teoretică a arhitecturii **RTNet (Relation Transformer Network)** propusă de **Huang et al. [7]** este evidentă prin integrarea mecanismelor de atenție, validarea practică a acestora necesită o demonstrație riguroasă a faptului că fiecare modul propus contribuie activ la îmbunătățirea segmentării. În acest sens, autorii au realizat un studiu extensiv de ablație (ablation study), analizând impactul incremental al componentelor arhitecturale asupra capacității de învățare și generalizare a rețelei.

Această analiză comparativă este sintetizată în graficele de performanță care monitorizează evoluția funcției de pierdere (Loss) și curbele Precision-Recall (PR) pentru cele patru tipuri principale de leziuni asociate retinopatiei diabetice: microanevrisme (MA), exudate (EX), hemoragii (HE) și exudate moi (SE).

Comparatia pornește de la un model **Baseline** (o rețea convoluțională standard de tip U-Net fără mecanisme de atenție) și adaugă progresiv componentele specifice RTNet, ca în figura 3:

1. **GTB (Global Transformer Block)**: Adăugarea capacității de procesare globală.
2. **SAH (Self-Attention Head)**: Introducerea atenției proprii pentru corelarea leziunilor similare.
3. **RAH (Relation Attention Head / Cross-Attention)**: Modulul critic care leagă leziunile de structura vaselor de sânge.
4. **RTB (Relation Transformer Block)**: Arhitectura completă propusă.




Figura 3. Curbele de Loss (stânga) și curbele Precision-Recall (dreapta) pentru studiile de ablație asupra celor patru leziuni DR. [7]

Lucrarea lui Huang et al. [7] validează ipoteza că integrarea informației globale prin Transformere este pasul necesar pentru a depăși plafonul de performanță atins de rețelele convoluționale pure în segmentarea medicală complexă.

Integrarea trăsăturilor globale și locale: Arhitectura Dual Branch [11]

Deși progresele în segmentarea semantică, ilustrate prin metodele bazate pe U-Net [12] sau pe Transformere [7], au permis o delimitare precisă a leziunilor, translatarea acestor detalii într-un diagnostic global (grading) rămâne o provocare majoră din cauza naturii subtile a diferențelor dintre stadiile retinopatiei diabetice. Rețelele convoluționale standard utilizate în studiile fundamentale, precum cel al lui Gulshan et al. [3], tind să piardă detaliile fine, cum ar fi microanevrismele incipiente, în procesul de redimensionare a imaginii necesar pentru analiza globală. Pentru a depăși acest compromis inerent între contextul vizual și rezoluția detaliilor, Shakibania et al. [11] au propus o arhitectură inovatoare de tip **Dual Branch Deep Learning Network**, care restructurează procesul de învățare prin decuplarea extragerii trăsăturilor în două fluxuri paralele distincte.

Conceptul central al acestei abordări constă în imitarea procesului cognitiv uman de diagnosticare, procesând imaginea simultan pe o „ramură globală” și o „ramură locală”. Ramura globală analizează imaginea completă a fundului de ochi pentru a captura structura generală a vaselor și geometria retinei, o strategie similară cu metodele clasice de Transfer Learning discutate de **Jabbar et al. [10]**. În paralel, ramura locală operează pe decupaje de înaltă rezoluție, fiind specializată în identificarea leziunilor microscopice care ar fi invizibile pentru rețeaua globală. Elementul de noutate adus de această lucrare față de abordările multi-task anterioare, precum cea propusă de **Wang et al. [6]**, este mecanismul sofisticat de fuziune a celor două fluxuri, care utilizează tehnici de atenție pentru a pondera importanța trăsăturilor locale în decizia finală, asigurând că un detaliu critic nu este ignorat în favoarea unei imagini de ansamblu aparent sănătoase.

Eficacitatea acestei arhitecturi hibride este validată prin rezultatele experimentale obținute pe seturile de date standard, unde modelul Dual Branch a demonstrat o superioritate clară în clasificarea stadiilor intermediare ale bolii (ușor și moderat). Analiza performanței indică faptul că integrarea informației locale crește semnificativ sensibilitatea modelului și reduce confuzia între clasele adiacente, oferind o robustețe superioară la variațiile de calitate a imaginii comparativ cu arhitecturile single-stream. Astfel, lucrarea lui Shakibania et al. [11] confirmă faptul că performanța SOTA în 2024 nu derivă doar din adâncimea rețelei, ci din capacitatea arhitecturală de a reuni viziunea macroscopică cu cea microscopică într-un diagnostic coerent.

Transparența decizională și generalizarea: Abordarea Explainable AI [9]

În timp ce arhitecturile sofisticate precum Dual Branch Network [11] sau Transformer-ele relaționale [7] au reușit să împingă limitele acurateței și ale segmentării fine, integrarea acestor sisteme în fluxul clinic real se lovește de o barieră fundamentală: lipsa de încredere a medicilor în algoritmi de tip „black-box”. Validarea clinică inițiată de **Gulshan et al. [3]** a demonstrat potențialul diagnostic, însă pentru ca un sistem de inteligență artificială să fie acceptat ca asistent de încredere, acesta trebuie să își poată justifica deciziile. În acest context, lucrarea „**Explainable end-to-end deep learning for diabetic retinopathy detection across multiple datasets**”, publicată de **Chetoui și Akhloufi [9]**, reprezintă un pilon esențial al stadiului actual al cunoașterii, adresând simultan două probleme critice: interpretabilitatea (Explainable AI - XAI) și robustețea pe seturi de date eterogene.

Metodologia propusă de autori se bazează pe o arhitectură de tip CNN modificată (utilizând backbone-uri precum DenseNet121 sau ResNet50), în care straturile clasice complet conectate sunt înlocuite cu **Global Average Pooling (GAP)**. Această modificare tehnică permite generarea **Hărților de Activare a Claselor (CAM)**, oferind medicului o confirmare vizuală a regiunilor patologice care au determinat diagnosticul.

Pentru a demonstra capacitatea superioară de generalizare a modelului – o problemă ridicată și de **Zhang et al. [8]** în contextul adaptării la domeniu – studiul se distinge prin cea mai vastă evaluare încrucișată din literatură, utilizând nu mai puțin de 7 seturi de date publice distincte, fiecare având caracteristici specifice de achiziție și calitate:

- **EyePACS (Kaggle):** Cel mai voluminos set de date disponibil (peste 88.000 de imagini), caracterizat printr-o variabilitate extremă a calității și a condițiilor de iluminare, folosit ca sursă principală de antrenare pentru a asigura robustețea.
- **APTOS 2019:** Un set de date recent (3.662 imagini) colectat în India, care prezintă o diversitate mare a patologiilor și echipamente moderne de captură.
- **MESSIDOR:** Considerat setul de referință („benchmark”) în comunitatea științifică europeană (1.200 imagini), având o calitate tehnică ridicată și etichete verificate riguros.
- **IDRiD (Indian Diabetic Retinopathy Image Dataset):** Un set complex (516 imagini) care include atât etichete de severitate, cât și măști de segmentare la nivel de pixel, util pentru validarea localizării leziunilor.
- **DDR (Dataset of Diabetic Retinopathy):** Un set de date masiv (13.673 imagini) provenit din China, care include adnotări fine pentru leziuni, oferind o perspectivă demografică diferită.
- **DiaRetDB1:** Un set de date mai mic (89 imagini), utilizat frecvent pentru calibrarea și testarea algoritmilor pe detalii fine, datorită calității vizuale excepționale.
- **HEI-MED (Hamilton Eye Institute Macular Edema):** Un set specializat (169 imagini) concentrat pe edemul macular diabetic, testând capacitatea modelului de a detecta complicațiile specifice ale bolii.




Figura 4. Exemple de imagini ale fundului de ochi în seturile de date DIARETDB0 și DIARETDB1 [9]

Relevanța clinică a acestei abordări extensive este evidențiată în rezultatele vizuale, unde hărțile de saliență generate de algoritm se suprapun cu precizie peste semnele patologice reale, indiferent de setul de date din care provine imaginea. Zonele marcate cu roșu intens pe hărțile CAM corespund anatomic cu microanevrismele și exudatele, confirmând că rețeaua neuronală a învățat trăsăturile intrinseci ale bolii și nu caracteristicile specifice ale camerei foto (bias-ul echipamentului). Prin urmare, modelul propus de Chetoui și Akhloufi [9] validează faptul că un sistem SOTA trebuie să fie nu doar precis, ci și agustic la sursa datelor și transparent în decizii.

Generalizarea în scenarii reale: Multi-Model Domain Adaptation [8]

Ultima frontieră în dezvoltarea sistemelor de diagnostic asistat de calculator (CAD) pentru retinopatia diabetică nu mai este legată strict de acuratețea obținută pe un singur set de date de antrenament, ci de capacitatea algoritmului de a funcționa corect într-un mediu clinic eterogen. În realitate, imaginile de fund de ochi variază drastic în funcție de modelul camerei funduscope, setările de iluminare, etnia pacientului sau protocolul de achiziție, fenomen cunoscut sub numele de *domain shift*. Modelele antrenate pe un „domeniu sursă” (de exemplu, imagini de înaltă calitate de la EyePACS) tind să aibă performanțe scăzute atunci când sunt aplicate pe un „domeniu țintă” (imagini clinice noi, cu caracteristici vizuale diferite), ceea ce limitează sever aplicabilitatea lor universală.

Pentru a soluționa această problemă critică de implementare, **Zhang et al. [8]** au propus în 2022 o metodă inovatoare denumită **Multi-Model Domain Adaptation (MMDA)**. Spre deosebire de abordările anterioare care încearcă să alinieze domeniile folosind un singur model, autorii introduc o arhitectură complexă bazată pe o rețea siameză, utilizând două modele distincte pentru a extrage trăsături complementare și pentru a crește robustețea deciziei.

Inovația tehnică centrală a lucrării constă în integrarea simultană a trei mecanisme de optimizare care lucrează concertat pentru a forța modelul să ignore diferențele stilistice dintre seturile de date și să se concentreze exclusiv pe patologie. Astfel, arhitectura combină o pierdere de clasificare pentru a asigura acuratețea diagnostică pe domeniul sursă etichetat, cu o pierdere de discrepanță care maximizează diferența dintre predicțiile celor două clasificatoare pe domeniul țintă pentru a detecta exemplele aflate la granița de decizie. În plus, se utilizează o pierdere de adaptare adversarială care, prin intermediul unui discriminator, minimizează distanța dintre distribuția trăsăturilor din sursă și cea din țintă, făcând ca imaginile provenite din spitale diferite să fie reprezentate similar de către rețeaua neuronală.

Validarea experimentală a metodei a fost realizată folosind setul de date **EyePACS** ca domeniu sursă și **Messidor-2** ca domeniu țintă, simulând un scenariu realist de transfer tehnologic de la imagini de screening la imagini clinice de referință. Rezultatele au demonstrat că abordarea MMDA depășește semnificativ metodele standard de antrenare și alte tehnici de adaptare cunoscute, obținând o îmbunătățire substanțială a metricilor de performanță pe domeniul țintă fără a necesita etichete pentru acesta. Această lucrare încheie logic analiza stadiului actual al cunoașterii, subliniind faptul că un sistem SOTA complet nu trebuie doar să segmenteze leziuni fine sau să fie explicabil, ci trebuie să fie capabil să iasă din mediul controlat al laboratorului și să ofere o performanță robustă și generalizabilă în diversele condiții întâlnite în practica medicală globală.

Referințe

[1] M. Niemeijer et al., "Automatic detection of red lesions in digital color fundus photographs," *IEEE Transactions on Medical Imaging*, vol. 24, no. 5, pp. 584-592, 2005.

- [2] A. Sopharak, B. Uyyanonvara, and S. Barman, "Automatic exudate detection from non-dilated diabetic retinopathy retinal images using fuzzy c-means clustering," *Sensors*, vol. 9, no. 3, pp. 2148-2161, 2009.
- [3] V. Gulshan et al., "Development and validation of a deep learning algorithm for detection of diabetic retinopathy in retinal fundus photographs," *JAMA*, vol. 316, no. 22, pp. 2402-2410, 2016.
- [4] H. Pratt et al., "Convolutional neural networks for diabetic retinopathy," *Procedia Computer Science*, vol. 90, pp. 200-205, 2016.
- [5] O. Ronneberger, P. Fischer, and T. Brox, "U-net: Convolutional networks for biomedical image segmentation," in *International Conference on Medical Image Computing and Computer-Assisted Intervention (MICCAI)*, Cham: Springer, pp. 234-241, 2015.
- [6] X. Wang et al., "Deep multi-task learning for diabetic retinopathy grading in fundus images," in *Proceedings of the AAAI Conference on Artificial Intelligence*, vol. 35, no. 4, pp. 2728-2736, 2021.
- [7] S. Huang et al., "RTNet: Relation transformer network for diabetic retinopathy multi-lesion segmentation," *IEEE Transactions on Medical Imaging*, vol. 41, no. 6, pp. 1596-1607, 2022.
- [8] G. Zhang et al., "Multi-model domain adaptation for diabetic retinopathy classification," *Frontiers in Physiology*, vol. 13, art. 918929, 2022.
- [9] M. Chetoui and M. A. Akhloufi, "Explainable end-to-end deep learning for diabetic retinopathy detection across multiple datasets," *Journal of Medical Imaging*, vol. 7, no. 4, art. 044503, 2020.
- [10] M. K. Jabbar et al., "Transfer learning-based model for diabetic retinopathy diagnosis using retinal images," *Brain Sciences*, vol. 12, no. 5, art. 535, 2022.
- [11] H. Shakibania et al., "Dual branch deep learning network for detection and stage grading of diabetic retinopathy," *Biomedical Signal Processing and Control*, vol. 93, art. 106168, 2024.
- [12] N. Sambyal et al., "Modified U-Net architecture for semantic segmentation of diabetic retinopathy images," *Biocybernetics and Biomedical Engineering*, vol. 40, no. 3, pp. 1094-1109, 2020.